

Laporan Praktikum Kontrol Cerdas

Week 4

Nama : Mochamad Reza Arimurti

NIM 214308017

Kelas : TKA-6A

Akun Github (Tautan) : <https://github.com/jaezr1>

Student Lab Assistant : Muhammad Fatih Anfa Ahima (214308092)

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

Pada akhir praktikum ini, mahasiswa akan dapat:

1. Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
2. Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
3. Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
4. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
5. Menggunakan GitHub untuk version control dan dokumentasi praktikum.

3. Landasan Teori

Apa itu Reinforcement Learning?

Reinforcement Learning (RL) adalah metode pembelajaran di mana agen belajar mengambil keputusan melalui interaksi dengan lingkungan. Agen memperoleh reward atau penalty sebagai umpan balik dari tindakannya, sehingga ia dapat mengoptimalkan strategi untuk mencapai tujuan tertentu.

Penerapan RL dalam Autonomous Control

Beberapa contoh penerapan RL antara lain:

- Navigasi Robot: Mengontrol pergerakan robot dalam lingkungan yang dinamis.
- Kendaraan Otonom: Mengambil keputusan berkendara berdasarkan kondisi lingkungan.
- Optimasi Rute dan Proses: Mengatur pergerakan dalam pabrik, gudang, atau sistem logistik

4. Analisis dan Diskusi

Analisis

1. Kinerja Agen dalam Mengendalikan Lingkungan CartPole

Seiring dengan proses pelatihan, kinerja agen menunjukkan peningkatan yang signifikan, ditandai dengan skor yang bertambah hingga mencapai nilai tinggi yang lebih stabil.

Pada tahap awal pelatihan, penggunaan epsilon yang besar mendorong agen untuk mengeksplorasi berbagai tindakan, sementara penurunan epsilon di tahap berikutnya memungkinkan agen mengeksploitasi kebijakan yang telah dipelajari untuk menjaga keseimbangan tiang di atas kereta.

Ketika agen telah terlatih dengan baik, pada tahap pengujian dengan epsilon rendah, ia seharusnya mampu mempertahankan keseimbangan tiang dalam waktu yang lebih lama.

2. Dampak Perubahan Parameter terhadap Kinerja Agen

Gamma (discount factor):

Gamma dengan nilai tinggi (~ 0.99) membuat agen lebih memperhatikan keuntungan jangka

panjang, yang ideal untuk tugas seperti CartPole.

Sebaliknya, gamma yang rendah (~ 0.5) menyebabkan agen berfokus pada reward jangka pendek, yang dapat menghasilkan keputusan yang kurang optimal.

Epsilon (exploration rate):

Epsilon awal yang tinggi (1.0) memungkinkan agen mengeksplorasi banyak tindakan, namun perlu dikurangi secara bertahap untuk menghindari keputusan acak yang tidak efisien.

Jika epsilon menurun terlalu cepat, eksplorasi menjadi tidak memadai, sedangkan penurunan yang terlalu lambat memperlambat proses pembelajaran.

Learning rate:

Learning rate yang optimal (0.001) menciptakan keseimbangan antara kecepatan konvergensi dan kestabilan proses pelatihan.

Nilai yang terlalu besar dapat menyebabkan pelatihan menjadi tidak stabil, sedangkan nilai yang terlalu kecil membuat proses pembelajaran berlangsung lambat.

3. Tantangan dalam Melatih Agen RL

Ketidakstabilan dalam Proses Pembelajaran: Karena DQN memperbarui nilai Q berdasarkan estimasi internalnya sendiri, hal ini dapat menyebabkan ketidakstabilan selama pelatihan.

Eksplorasi yang Tidak Efektif: Jika penurunan epsilon (epsilon decay) tidak dikonfigurasi dengan benar, agen mungkin gagal menemukan kebijakan yang optimal.

Overfitting pada Lingkungan Tertentu: Agen dapat menunjukkan performa yang sangat baik di lingkungan pelatihan tetapi kesulitan beradaptasi di lingkungan lain.

Diskusi

1. Perbedaan antara Reinforcement Learning dan Supervised Learning dalam Sistem Kendali

Supervised Learning memerlukan data berlabel sebagai panduan selama pelatihan, sedangkan Reinforcement Learning belajar melalui interaksi langsung dengan lingkungan tanpa membutuhkan label eksplisit.

Reinforcement Learning lebih sesuai untuk sistem kendali karena mampu menyesuaikan strategi berdasarkan umpan balik dari lingkungan secara dinamis, tanpa memerlukan dataset yang telah ditentukan sebelumnya.

2. Optimalisasi Strategi Eksplorasi dan Eksploitasi dalam RL

Epsilon-Greedy Decay: Memulai dengan tingkat eksplorasi yang tinggi dan secara bertahap beralih ke eksploitasi seiring waktu.

Upper Confidence Bound (UCB): Memprioritaskan tindakan dengan ketidakpastian tinggi untuk memastikan eksplorasi yang lebih efisien.

Boltzmann Exploration: Memilih tindakan berdasarkan probabilitas yang dihitung dari nilai Q, bukan hanya memilih tindakan dengan nilai tertinggi.

2. Potensi Penerapan RL dalam Sistem Kendali Nyata

Robotika: RL diterapkan untuk mengatur pergerakan robot secara optimal di berbagai situasi.

Kendaraan Otonom: RL digunakan untuk membantu navigasi dan pengambilan keputusan dalam mobil tanpa pengemudi.




Sistem Manajemen Energi: RL mengoptimalkan konsumsi energi di gedung pintar dan jaringan listrik.

Trading Saham: Agen RL digunakan untuk mempelajari dan menerapkan strategi optimal dalam perdagangan saham dan mata uang kripto.

5. Assignment

- Modifikasi algoritma DQN dengan menambahkan teknik seperti target network untuk meningkatkan stabilitas pelatihan.
- Uji agen pada environment lain seperti LunarLander-v2 atau MountainCar-v0 dan bandingkan performanya.
- Eksperimen dengan variasi parameter dan dokumentasikan pengaruhnya terhadap kinerja agen.
- Upload semua hasil eksperimen ke GitHub dan buat laporan singkat mengenai analisis dan temuan Anda

6. Data dan Output Hasil Pengamatan

No	Variabel	Hasil data
	carthpole	
	Modifikasi algoritma DQN dengan menambahkan teknik target network	
	environment LunarLander-v2	

7. Kesimpulan

Target network meningkatkan stabilitas pelatihan, terutama dalam lingkungan yang kompleks seperti LunarLander-v2.

DQN yang dimodifikasi lebih adaptif pada berbagai environment, tetapi performanya tetap bergantung pada tuning parameter.

Eksplorasi yang cukup dan parameter yang tepat sangat berpengaruh terhadap keberhasilan agen RL dalam mencapai performa optimal.

GitHub membantu dalam version control dan dokumentasi, memudahkan eksperimen serta analisis perubahan model.

8. Saran

Dalam tugas ini, disarankan untuk memperluas eksplorasi metode Reinforcement Learning (RL) dengan membandingkan berbagai algoritma seperti Deep Q-Network (DQN), Proximal Policy Optimization (PPO), dan Soft Actor-Critic (SAC) dalam pengendalian sistem otonom. Selain itu, analisis mendalam terhadap parameter hiper (seperti laju pembelajaran, discount factor, dan ukuran replay buffer) dapat memberikan wawasan mengenai kinerja model. Pengujian pada lingkungan simulasi yang lebih kompleks, seperti OpenAI Gym atau CARLA Simulator, dapat meningkatkan validitas hasil dan menunjukkan bagaimana algoritma RL menangani ketidakpastian di dunia nyata. Terakhir, mengevaluasi stabilitas dan efisiensi pembelajaran dari berbagai algoritma akan memberikan pemahaman yang lebih komprehensif terkait penerapan RL di bidang pengendalian otonom.

9. Daftar Pustaka

Bahare Kiumarsi, K. G. Vamvoudakis, H. Modares, & F. L. Lewis. (2018).

Optimal and autonomous control using reinforcement learning: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 29(6), 2042–2061.

Archit Sharma, Kelvin Xu, Nikhil Sardana, Abhishek Gupta, Karol Hausman, Sergey Levine, & Chelsea Finn. (2021).

Autonomous reinforcement learning: Formalism and benchmarking. *arXiv preprint arXiv:2112.09605*.

Frank L. Lewis, D. Vrabie, & V. Syrmos. (2012). *Optimal control* (3rd ed.). John Wiley and Sons.
